手机制造厂内部培训 · AI推进小组

MOBILE FACTORY · AI GLOSSARY HANDBOOK

手机厂AI术语手册

30天AI术语科普营 · 完整收藏版

30	4	3	∞
个核心术语	大主题	类岗位适用	实战场景

版本 V1.0 · 2026年4月 · 全员可收藏

写在前面

这本手册是「30天AI术语科普营」的完整收藏版。过去30天，我们每天推送一个AI核心术语，用手机厂真实场景讲故事，让不写代码的同事也能听懂AI。

这本手册把30个术语全部整理在一起，方便你随时查阅。无论是**厂长审核AI报价单**、**工程师排查AI报错**，还是**品质工程师了解AI质检能做什么**，都能在这里找到答案。

记住这句话：**AI不是魔法，也不是威胁——它是一套新工具，等待被有准备的人用好。**

管理层怎么用

快速扫描每个术语的「一句话定义」和「管理层场景」，掌握AI采购决策所需的基础认知，不被供应商忽悠。

工程师怎么用

重点阅读每个术语的「技术原理」和「常见误区」，掌握工具正确用法，避开高频报错和踩坑。

品质/IE怎么用

聚焦「制造业场景」部分，找到AI在质检、报告、流程优化上的切入点，知道AI能帮你做什么。

手册使用说明

按周分章，颜色编码：🔵第一周基础概念 · 🟢第二周核心技术 · 🟣第三周应用模式 · 🟡第四周制造落地。

目录

第一周 · AI基础概念 · Day 01–07

Day 01	Token	AI计量单位，决定成本与能力边界
Day 02	Prompt	给AI的指令，好坏直接决定输出质量
Day 03	大模型	AI的大脑，参数越多能力上限越高
Day 04	上下文窗口	AI的工作记忆，超限就会「忘事」
Day 05	多模态	AI同时理解文字、图片、语音
Day 06	训练与微调	让AI从通用变专业的核心方法
Day 07	推理	训练完成后AI「思考并回答」的过程

第二周 · AI核心技术 · Day 08–14

Day 08	MCP协议	让AI连接外部工具和系统的标准协议
Day 09	AI Agent	能自主规划和执行多步骤任务的AI
Day 10	工具调用/Skill	AI调用外部程序完成搜索、计算等任务
Day 11	LLM大语言模型	基于海量文本训练的通用语言AI
Day 12	Embedding嵌入	把文字变成数字向量，让AI理解语义
Day 13	RAG	检索增强生成，让AI基于你的文档回答
Day 14	向量数据库	专门存储和检索Embedding向量的数据库

第三周 · AI应用模式 · Day 15–21

Day 15	AIGC	AI生成内容：图、文、视频、代码
Day 16	生成式AI	能创作新内容而非仅做分类的AI
Day 17	判别式AI	专门做分类和判断的传统AI
Day 18	计算机视觉CV	让AI看懂图像和视频的技术
Day 19	自然语言处理NLP	让AI理解和生成人类语言的技术
Day 20	多智能体协作	多个AI分工合作完成复杂任务
Day 21	微调 vs RAG	让AI懂专业领域的两条核心路线

第四周 · AI制造落地 · Day 22–30

Day 22	**AI原生应用**	从设计阶段就以AI为核心的新型应用
Day 23	**端侧AI**	AI运行在本地设备芯片，无需联网
Day 24	**云侧AI**	AI运行在远端服务器，算力强大
Day 25	**AI+智能制造**	AI接入工厂MOM系统的完整路径
Day 26	**预测性维护**	AI提前预测设备故障，变被动为主动
Day 27	**AI质检**	用AI相机替代人工AOI，大幅降低误报
Day 28	**参数规模**	AI模型的知识容量，决定能力上限
Day 29	**AI幻觉**	AI自信地说错话的现象及防范方法
Day 30	**AGI**	通用人工智能，能胜任任何人类认知任务

WEEK 01

第一周

AI 基础概念

Token　Prompt　大模型　上下文窗口　多模态

训练与微调　推理

DAY 01

Token

// TOKEN · AI的计量单位

Token是AI处理文字的最小单位，也是AI服务的计费单位。中文约1.5个汉字=1 Token，英文约4个字母=1 Token。

📍 工厂场景

管理层：厂长看AI报价单：「按Token计费，一个月5000万个Token，这是什么单位？」— 简单换算：SOP作业指导书3000字/份 × 500份 ≈ 150万字 ÷ 1.5 ≈ 100万Token。先估Token总量再谈报价，不被供应商忽悠。

工程师：PE工程师把100份ECN文件一次丢进AI，报错「Context length exceeded」— 原因正是超出了Token上限。解决：分批上传，每批不超过上限的80%。

🏭 手机产线：你投进去的物料→**Input Token**；SMT贴片机加工→**大模型推理**；产出的PCBA成品→**Output Token**。Token就是AI世界的「物料计量单位」。

✅ 实用公式

字数 ÷ 1.5 ≈ 中文Token数
字数 ÷ 4 ≈ 英文Token数

💡 成本意识

Input Token和Output Token分开计费，回答越长成本越高，适当设置「回复字数限制」可省成本。

❌ 常见误区

「文件越大Token越多」不完全对——Token数取决于文字数量，而非文件大小（PDF图片不消耗Token）。

DAY 02

Prompt

// PROMPT · 给AI的指令

Prompt是你给AI的输入指令。同样的问题，Prompt写法不同，输出质量可以天差地别。

📍 工厂场景

差的Prompt：「帮我写品质报告」→ AI输出通用模板，与工厂实际数据无关。

好的Prompt：「你是SMT品质工程师。本周A线良率92.3%（目标95%），主要不良：锡珠42ppm、偏位28ppm。请用工厂周报格式输出：问题分析+根因推断+改善措施+下周目标，300字以内。」→ 直接可用的专业报告。

📋 Prompt就像**作业指导书SOP**——同一台设备，SOP越详细操作越标准；同一个AI，Prompt越清晰输出越精准。

✅ Prompt四要素

① 角色（你是谁）
② 任务（做什么）
③ 背景（什么情况）
④ 格式（怎么输出）

💡 工厂实用模板

「你是[岗位]。情况是[具体数据]。请[具体任务]，格式要求[限制条件]。」

❌ 常见误区

不是Prompt越长越好——清晰、具体、结构化比单纯堆字数更有效。

DAY 03

大模型

// LARGE LANGUAGE MODEL · LLM

大模型是用海量数据训练的超大规模AI，参数量从数十亿到数千亿，具备语言理解、推理、创作等通用能力。

工厂场景：供应商说「我们大模型什么都能做」— 正确理解：大模型是通用基础，但不等于万能。它需要结合工厂数据（RAG或微调）才能真正「懂制造」。大≠强，关键看任务匹配度。

🏫 大模型像**全科博士毕业生**——什么都懂一点，但进工厂后还需要3个月熟悉具体工艺流程。「通用聪明」和「专业胜任」是两回事。

✅ 主流大模型

GPT-5.4（OpenAI）
Claude Opus 4.6（Anthropic）
Llama 3.1 70B（开源，可私有化）

💡 选型建议

简单任务选小模型（省钱）
复杂推理选旗舰模型
数据敏感选私有化开源模型

❌ 常见误区

「大模型参数越多越好」— 参数决定容量上限，但训练数据质量、RLHF对齐同样关键。Phi-4（14B开源）在数学推理上能超过多个千亿模型。

DAY 04

上下文窗口

// CONTEXT WINDOW · AI的工作记忆

上下文窗口是AI在一次对话中能「记住」的最大信息量。超出上限，AI就会「忘记」前面的内容。

工厂场景：PE工程师把100份ECN文件一次性丢进AI，报错「Context length exceeded」— 这就是超出了上下文窗口。解决方案：① 分批处理；② 先摘要再汇总；③ 用RAG技术让AI按需检索。

🔧 上下文窗口就像**工作台的台面大小**——台面越大能同时摊开的图纸越多，超出台面的材料只能先放地上（被遗忘）。GPT-5.4的台面是100万Token，普通模型是10万Token。

✅ 实用策略

超长文档：先让AI提取摘要，再对摘要提问，节省80%Token消耗。

💡 各模型窗口

GPT-5.4：1,000,000 Token
Claude Opus 4.6：200,000 Token
Llama 3.1：128,000 Token

❌ 常见误区

「上下文窗口越大，AI越聪明」— 窗口大只是能「装」更多信息，理解和推理质量与窗口大小无关。

DAY 05

多模态

// MULTIMODAL · 多感官AI

多模态AI能同时理解和生成文字、图片、语音、视频等多种形式的信息，不再局限于纯文字交互。

工厂场景：品质工程师拍下PCB板焊接缺陷照片，直接发给多模态AI，AI能描述缺陷类型、推断根因、建议处理方案——全程无需打字描述缺陷，效率提升3倍以上。

👁️ 单模态AI是**只能看文字的工程师**；多模态AI是**能同时看图纸、听描述、读报告的全能助手**。眼耳脑同时工作，处理复杂问题更高效。

✅ 工厂用法

上传设备报错截图→AI分析
上传缺陷照片→AI识别类型
上传电路图→AI解读标注

💡 注意事项

图片质量影响识别精度。模糊、背光、角度不正的图片，AI理解准确率会显著下降。

❌ 常见误区

「多模态就是AI质检」— 多模态是AI感知能力，AI质检是多模态的一个应用场景，两者不能画等号。

DAY 06

训练与微调

// TRAINING & FINE-TUNING

训练是从零让AI学习海量数据；微调是在已有大模型基础上，用少量专业数据让它更擅长特定领域。

工厂场景：供应商报价「帮你微调模型，让AI学会我们的SOP」— 正确评估：微调适合让AI掌握特定语气风格和格式，但不适合作为知识库（用RAG更合适）。微调成本：数千到数万元不等，需确认需求再决策。

🎓 **预训练** = 大学通识教育（学所有知识）；**微调** = 入职培训（专学工厂业务）；**RAG** = 工程师带着参考手册上岗（不背书，查书）。三种路线适用场景不同。

✅ 微调适合

- 固定回答风格/格式
- 特定领域术语学习
- 低延迟实时推理任务

❌ 微调不适合

- 知识库查询（用RAG）
- 频繁更新的内容
- 预算有限的场景

❌ 常见误区

「微调过的AI更聪明」— 微调改变的是AI的行为习惯，不提升基础推理能力。能力上限由基础大模型决定。

DAY 07

推理

// INFERENCE · AI的思考过程

推理是训练完成后的AI接收问题、调用参数、生成回答的完整过程。推理速度和成本直接影响AI产品体验。

工厂场景：工厂部署AI质检系统，每张PCB板图片的「推理」需要在200毫秒内完成，否则影响产线节拍。推理速度直接决定AI系统能否上线——这是AI落地最核心的工程挑战之一。

⚡ 推理就像**已毕业工程师处理一个问题的过程**——读题→查知识→思考→输出答案。训练好比上学，推理好比工作。上学只做一次，工作每天都在发生。

✅ 推理优化方向

- 端侧推理（手机/边缘设备）
- 量化压缩（模型变小更快）
- 批处理（多任务并行）

💡 成本构成

推理成本 = GPU费用 × 时间

工厂选型需评估：延迟要求 vs 成本预算 vs 精度需求

❌ 常见误区

「AI训练一次就够了」— 训练是一次性的，但推理（使用AI）是持续产生成本的。部署前必须评估推理成本。

WEEK 02

第二周

AI 核心技术

MCP协议 | AI Agent | 工具调用 | LLM | Embedding | RAG | 向量数据库

DAY 08

MCP协议

// MODEL CONTEXT PROTOCOL

MCP（模型上下文协议）是让AI安全连接外部工具、数据库、系统的标准接口协议，由Anthropic发起制定。

工厂场景：通过MCP，工厂的AI助手可以直接调用MES系统查询今日产量、连接ERP读取订单数据、向飞书发送通知——无需人工转述数据，AI直接「上网」获取实时信息。有了MCP，AI从「聊天工具」变成「系统操作员」。

🔌 MCP就像**工厂设备的统一通信协议（如Modbus）**——不同品牌的设备只要支持同一协议，就能被统一系统管控。MCP让不同AI能连接不同系统，不用每次单独开发接口。

❌ **常见误区**

「用了MCP，AI就能自动做任何事」— MCP解决的是「连接」问题，AI能做什么还取决于具体工具和权限设置。

DAY 09

AI Agent

// AI AGENT · 自主智能体

AI Agent是能自主规划、分解任务、调用工具、执行多步骤操作的AI系统，不需要人工逐步指令。

工厂场景：传统AI：你问一句它答一句。AI Agent：你说「帮我分析本周A线异常并生成改善报告」，它自动查MES数据→分析趋势→识别根因→起草报告→发飞书给负责人，全程自动完成，中间无需人工干预。

🤖 Agent就像**能独立完成任务的实习生**——你给目标，它自己规划路径、调用资源、完成任务、汇报结果。不像普通AI只能「一问一答」。

❌ **常见误区**

「AI Agent会失控」— 工厂部署的Agent有明确权限边界，无法越权操作。关键决策节点必须设置「人工审批」环节。

DAY 10

工具调用 / Skill

// TOOL CALLING · FUNCTION CALLING

工具调用让AI在对话中自动调用外部程序（搜索、计算、查数据库），获取实时信息后再生成回答。

工厂场景：AI助手被问「今天A线良率多少？」——没有工具调用：AI只能回答「我不知道实时数据」。有工具调用：AI自动查MES接口→获取实时良率→整合成回答「今天A线良率93.2%，比昨天下降0.8%」。

🛠️ 工具调用就像**给工程师配备专业仪器**——工程师（AI）本身有知识，但需要万用表（搜索工具）、示波器（数据库工具）才能做精确分析。工具调用让AI从「纯靠记忆」到「实时查证」。

❌ **常见误区**

「AI能调用工具就什么都知道」— 工具调用的质量取决于工具的数据质量。MES数据不准，AI分析结果也不准。

DAY 11

LLM 大语言模型

// LARGE LANGUAGE MODEL

LLM是用海量文本数据训练的大规模神经网络，能理解和生成人类语言，是当前AI应用的核心引擎。

工厂场景：ChatGPT、Claude、文心一言都是LLM的产品化形态。工厂部署AI知识库、AI报告助手、AI质检判定说明，底层都在调用LLM。LLM与传统软件的本质区别：传统软件执行固定逻辑；LLM理解意图，灵活应对未见过的问题。

🧠 LLM就像**读过几乎所有书的图书馆员**——知识面广，能理解模糊问题，能跨领域联想，但不保证每个答案都准确（存在幻觉风险）。

❌ **常见误区**

「LLM=AI全部」— LLM是生成式AI的核心，但计算机视觉质检、预测维护等用的是不同技术路线，并不依赖LLM。

DAY 12

Embedding 嵌入

// EMBEDDING · 语义向量化

Embedding是把文字转换成数字向量的技术，让计算机能计算语义相似度，是搜索和RAG的基础。

工厂场景：工厂有10年维修记录，想让AI找出「回流焊温度过高」相关的历史案例——传统关键词搜索需要精确匹配文字；Embedding搜索能找到「焊点过热」「锡球氧化」「高温异常」等语义相近的记录，命中率提升3-5倍。

📍 Embedding就像给每个文档标注**GPS坐标**——语义相近的文档坐标相近，搜索时找「坐标附近的文档」而非「文字完全一样的文档」。

❌ **常见误区**

「Embedding搜索替代关键词搜索」— 两者互补。精确型查询（如产品型号、零件编号）用关键词更准；模糊型查询（如「相似问题」「相关案例」）用Embedding更好。

DAY 13

RAG

// RETRIEVAL AUGMENTED GENERATION · 检索增强生成

RAG让AI在生成回答前，先从你的文档库中检索相关内容，再基于真实文档回答，大幅减少幻觉。

工厂场景：工厂SOP知识库：上传500份SOP文件→建立向量索引→员工问「回流焊温度怎么设」→AI检索到对应SOP章节→基于实际文档回答，附带原文引用。比「微调大模型」成本低10倍以上，且内容可随时更新。

👨‍⚕️ RAG就像**带着参考书的工程师**——不要求把所有SOP背进大脑（微调），而是遇到问题就查书（检索），基于原文给出答案，更准确也更省钱。

❌ **常见误区**

「RAG能完全消除幻觉」— RAG大幅降低幻觉风险，但不能完全消除。AI仍可能错误理解检索到的文档内容，关键数据仍需人工核实。

DAY 14

向量数据库

// VECTOR DATABASE · 语义存储引擎

向量数据库专门存储Embedding向量，支持高效的语义相似度搜索，是RAG知识库的核心存储引擎。

工厂场景：工厂AI知识库技术栈：文档→Embedding模型转换→向量数据库存储→用户提问→语义检索→找到相关文档→AI生成答案。向量数据库是RAG系统的「仓库」，决定检索速度和精度。常用：Chroma（轻量）、Weaviate（生产级）。

🗄️ 传统数据库存的是「精确数据」（如零件编号、数量）；向量数据库存的是「语义坐标」。前者问「零件编号等于X」，后者问「和X最相似的是哪些」。

❌ **常见误区**

「向量数据库替换MES数据库」— 两者完全不同用途。MES存业务数据，向量数据库存知识语义，应互补而非替换。

WEEK 03

第三周

AI 应用模式

AIGC | 生成式AI | 判别式AI | 计算机视觉 | NLP | 多智能体 | 微调 vs RAG

DAY 15

AIGC

// AI GENERATED CONTENT · AI生成内容

AIGC指由AI自动生成的内容，包括文字、图片、视频、代码、音频等，是生成式AI的核心应用场景。

工厂场景：① 品质报告自动生成（文字AIGC）；② 产品渲染图生成（图片AIGC）；③ 多国语言培训材料自动翻译（文字AIGC）；④ 设备操作视频自动配字幕（音视频AIGC）。AIGC不替代人，而是把人从重复性内容生产中解放出来。

✍️ AIGC就像给每个部门配了一个**24小时不休息的内容助理**——不需要创意决策，只需要生产执行，AI来做；需要创意和判断，人来把关。

❌ **常见误区**

「AIGC内容可以直接用」— AIGC内容必须经人工审核，尤其是涉及技术参数、合规条款的内容，AI可能生成错误信息。

DAY 16

生成式AI

// GENERATIVE AI · 创造新内容的AI

生成式AI能创作全新内容（文字/图片/代码），而非只分类已有数据；ChatGPT、Midjourney都是典型代表。

工厂场景 vs 传统BI对比：传统BI数据分析：给定模板，输出固定格式报表，无法回答「为什么」。生成式AI分析：理解问题意图，生成灵活的分析叙述，能解释趋势、推断原因、提出建议——从「显示数据」到「理解数据」的质变。

🎨 传统AI是**会「识别」的AI**（看图说类别）；生成式AI是**会「创作」的AI**（从描述生成图）。前者判别，后者生成，方向相反。

❌ **常见误区**

「生成式AI会取代所有传统AI」— 工厂质检、预测维护等场景，判别式AI反而更准确、更高效。两种AI各有擅长领域。

DAY 17

判别式AI

// DISCRIMINATIVE AI · 分类识别的AI

判别式AI专门做分类、识别、判断工作，给定输入后输出类别标签（OK/NG、正常/异常），是工厂质检AI的主要技术路线。

工厂场景：AOI升级版AI质检用的正是判别式AI——摄像头拍下焊点图片→AI判断「OK」或「NG（划痕/虚焊/偏位）」。速度快（毫秒级）、精度高（>99%）、可重复，完全适合高速产线。相比之下，生成式AI来做质检则慢且贵。

⚖️ 判别式AI是**经验丰富的质检员**——见过10万张图，一眼判断OK还是NG，不需要「描述」缺陷，只需要给结论。效率比生成式AI高10倍以上。

❌ **常见误区**

「判别式AI已经过时」— 在工厂质检、设备状态识别等高速分类场景，判别式AI依然是首选，因为速度和成本优势显著。

DAY 18

计算机视觉 CV

// COMPUTER VISION · 让AI看懂图像

计算机视觉让AI理解图片和视频内容，能完成目标检测、缺陷识别、姿态估计等视觉任务。

工厂场景： ① PCB板焊接缺陷检测（划痕/虚焊/短路）；② 手机外壳外观检查（凹坑/划伤/色差）；③ 工人操作规范性检测（佩戴手套/静电环）；④ 来料外观检验自动化。CV是AI质检的核心技术，精度可达99.5%以上，速度远超人眼。

📷 CV就像**给AI装上眼睛**，而且是每秒能检查1000张图、永不疲劳、不受情绪影响的「超人眼睛」。精度和速度都超过人工，但需要大量标注数据训练。

❌ **常见误区**

「CV AI上线就万事大吉」— CV模型需要定期用新缺陷样本更新训练，否则对新型缺陷的识别率会下降。

DAY 19

自然语言处理 NLP

// NATURAL LANGUAGE PROCESSING

NLP让AI理解和生成人类语言，是AI助手、自动翻译、文档摘要、情感分析等应用的基础技术。

工厂场景： ① 多语言SOP自动翻译（中→英/法/斯瓦希里语）；② 会议纪要自动生成；③ 客诉邮件情感分类（紧急/一般/投诉）；④ 技术报告关键信息提取。非洲市场多语言需求正是NLP的典型应用——AI实现「所有语言的工厂」。

CV让AI看懂图；NLP让AI听懂话、读懂文。两者结合（多模态）让AI能同时处理「产线照片+工程师描述」，给出综合判断。

❌ **常见误区**

「NLP翻译直接可用」— 专业技术文档翻译需要人工审核，特别是工艺参数、安全警告等关键内容，AI可能误译专有名词。

DAY 20

多智能体协作

// MULTI-AGENT COLLABORATION

多智能体是多个AI分工协作完成复杂任务的系统，由指挥Agent调度多个专业Agent各司其职。

工厂场景：月度生产报告自动化：指挥Agent接到任务→数据Agent查MES拉良率数据→分析Agent找异常根因→写作Agent生成报告草稿→格式Agent排版为PPT→审核提醒Agent发飞书给负责人审批。全程无需人工逐步操作，从2天压缩到30分钟。

👥 多智能体就像**一个AI版的项目团队**——PM负责任务拆分，数据分析师拉数据，文案负责写稿，设计负责排版，每个角色都是专业AI，统一由PM（指挥Agent）协调。

❌ **常见误区**

「Agent越多越好」— Agent数量增加会导致错误叠加，关键流程节点必须设置人工检查点，防止错误级联放大。

DAY 21

微调 vs RAG

// FINE-TUNING vs RAG · 两条路线

微调让AI「记住」知识（刻入大脑）；RAG让AI「查阅」知识（携带手册）。选哪条路取决于需求类型和成本预算。

选RAG的场景： ① SOP知识库查询（内容频繁更新）；② 合规条款检索（需要原文引用）；③ 历史案例搜索（数据量大）。

选微调的场景： ① 固定输出风格（如企业报告格式）；② 特定领域术语（SMT/PCB专业词）；③ 实时推理无法检索时。

两者结合： 微调负责语气风格 + RAG负责知识检索 = 最优方案。

📊 成本对比

RAG：文档处理+向量库（千元级）
微调：数据标注+训练费（万元级）

⚡ 更新速度

RAG：上传文档即更新（分钟级）
微调：需重新训练（天级）

❌ 常见误区

「微调比RAG更高级」— 不存在谁更高级，只有谁更适合。对大多数工厂知识库场景，RAG比微调更经济实用。

WEEK 04

第四周

AI 制造落地

AI原生 端侧AI 云侧AI AI+智能制造 预测维护 AI质检

参数规模 AI幻觉 AGI

DAY 22

AI原生应用

// AI-NATIVE APPLICATION

AI原生应用从设计之初就以AI为核心架构，而非在传统软件上附加AI功能，每次交互都产生个性化学习。

工厂场景对比：AI增强型：传统MES + AI插件（报表旁边加个聊天框）；AI原生型：系统本身基于自然语言交互，工程师说「分析本周良率异常」，系统自动定位数据、分析根因、推送改善建议——AI是主体，而非附件。

🚗 AI增强型就像**老卡车加装导航仪**；AI原生就像**特斯拉**——**从设计之初就把AI放在架构中心**，整个系统的感知、决策、执行都围绕AI重新设计。

❌ **常见误区**

「加了AI功能就是AI原生」— 在传统软件上加个AI问答框不叫AI原生，AI原生需要从数据架构开始重新设计。

DAY 23

端侧AI

// ON-DEVICE AI · 本地推理

端侧AI让模型直接在设备芯片（NPU）上运行，无需联网，实现毫秒级响应，保护数据隐私。

工厂场景：手机摄影AI（夜景/人像/防抖）在NPU本地运行，无需上传云端→零延迟+保护照片隐私。工厂产线边缘AI质检：相机芯片本地推理→200ms判断OK/NG→无网络依赖→产线节拍不受影响。适合非洲/南亚弱网市场的所有AI应用。

🏪 端侧AI就像**餐厅现做**：厨师（AI模型）就在厨房（设备芯片），食材（数据）不需要快递到中央工厂（云端），当场出品（实时推理），新鲜快速。

❌ **常见误区**

「端侧AI能力弱」— 针对特定任务微调的小模型（如摄影AI），在该任务上效果可超过通用大模型，且成本低100倍。

DAY 24

云侧AI

// CLOUD AI · 远端算力

云侧AI将模型部署在远端服务器（GPU集群），通过API调用，算力弹性扩展，适合复杂推理和大规模任务。

工厂场景对比：端侧（本地）：质检判断（实时/小模型/无网）；云侧（远端）：月报深度分析/多语言本地化/供应链决策（允许2-5秒延迟/复杂推理/高质量要求）。选型口诀：**实时感知选端侧，复杂推理选云侧。**

端侧AI = 社区诊所（快速处理常见问题）；云侧AI = 三甲医院（处理复杂重症，需要预约等待）。不是谁替代谁，而是各司其职。

❌ **常见误区**

「云侧AI比端侧AI更好」— 云侧AI算力强但有延迟和网络依赖。弱网环境、实时任务必须用端侧，强行用云侧反而体验更差。

DAY 25

AI + 智能制造

// AI + SMART MANUFACTURING

AI接入工厂MOM/MES系统，实现从「数据感知」到「智能决策」到「自动执行」的全链路闭环。

四层架构：① 设备层（传感器/PLC/摄像头）→ ② 数据层（MES/ERP/SCADA）→ ③ AI层（质检/预测/优化模型）→ ④ 执行层（自动报警/调参/排产）。
量化收益：故障响应时间45min→8min（-82%）；月报生成2天→30分钟（-96%）；良率提升约1.8%。

🚦 AI+制造就像城市智慧交通——传感器感知路况（设备层）→交通管理平台分析（AI层）→信号灯自动调整（执行层）。人只需设定目标，系统自动优化运行。

❌ **常见误区**

「AI接入就能立刻见效」— AI的收益建立在数据质量上。MES数据不完整、传感器数据不准，AI分析结果同样不准。数据治理是AI落地的前提。

DAY 26

预测性维护

// PREDICTIVE MAINTENANCE · PdM

预测性维护用AI分析设备传感器数据，提前预测故障发生时间，将「坏了才修」变成「还没坏就维护」。

工厂实际效果：回流焊机加装振动/温度传感器→AI建立正常振动基线→发现频谱异常（-14天）→提前推送预警→计划停机维护（-7天）→避免突发停机损失（约8万元/次+良率损失）。非计划停机减少70%以上，年度维护成本降低30-40%。

⌚ 预测维护就像**给设备戴上Apple Watch**——实时监测「设备健康指标」，心率（振动）异常提前预警，不等到「心肌梗塞（设备崩溃）」才处理。

❌ **常见误区**

「AI能预测所有故障」— 预测性维护对有传感器数据的机械故障效果好，对突发性电气故障、人为操作失误等随机事件预测能力有限。

DAY 27

AI 质检

// AI VISUAL INSPECTION

AI质检用计算机视觉替代人工AOI，对产品外观缺陷进行自动化检测，大幅降低误报率和漏检率。

量化价值：传统AOI误报率约8%→AI质检降至0.8%（-90%）。按每日500次报警计算：节省误报处理 = 40次/天 × 15分钟 = 600分钟 = 10人时/天 ≈ 每年节省约3500人时。同时识别AOI无法检出的细微缺陷（0.1mm以下划痕）。

🏅 传统AOI是**规则判题员**（灰度值超过阈值=NG，死板）；AI质检是**奥运评分裁判**（综合评估，区分「真的NG」和「光线反射误报」，精准判断）。

✅ 导入步骤

① 收集历史NG图片（至少200张/类）
② 标注缺陷位置和类型
③ 训练模型并验证
④ 与现有AOI并联运行
⑤ 验证误报率改善后切换

💡 数据要点

标注质量 > 标注数量。模糊边界标注导致模型混乱，宁可少一点、标得准一点。

DAY 28

参数规模

// MODEL PARAMETERS · 知识容量上限

参数是AI神经网络的连接权重，是模型「知识容量上限」的体现。参数越多，能处理的任务越复杂，但成本和延迟也成倍增加。

重要事实：主流闭源模型（Claude Opus 4.6、GPT-5.4）的参数量**官方从未披露**，网络上的数字均为非官方估算。开源模型（Llama 3.1 70B、Phi-4-mini 3.8B）参数官方公开可查。

工厂选型原则：实时感知（质检/摄影）→ 端侧小模型（<10B，参数公开）；专业问答 → 开源中型（70B，私有化）；复杂分析 → 旗舰云端（参数未披露，按能力表现选）。

📚 参数 = 图书馆藏书量，训练数据质量 = 书的质量，RLHF对齐 = 馆员专业培训。藏书多不代表回答好，三者同等重要。

❌ **常见误区**

「参数越多越聪明」— Phi-4（14B，开源公开）在数学推理上能超过多个参数量大10倍的模型。训练方法和数据质量同样决定能力。

DAY 29

AI 幻觉

// AI HALLUCINATION · 自信地说错话

AI幻觉是AI以高置信度生成错误信息的现象。AI不是在「查数据库」，而是在「预测最可能的文字」，所以可能自信地说出从未发生的事。

工厂高风险场景： ① 精确参数查询（「回流焊温度应该多少」→ AI可能给出错误数值，影响工艺执行）；② 标准规范引用（「IPC-A-610第X条」→ 条款可能不存在）；③ 数据报告（AI可能「补全」一个不存在的数字）。
低风险场景： 写作/翻译/格式转换（内容由人提供，AI做语言转化）。

🎭 AI幻觉就像**自信的失忆者**——问他任何问题，他都会立刻给出一个听起来非常合理的答案，哪怕他根本不知道正确答案。90%正确+10%错误比100%错误更危险。

🛡️ 防幻觉方法

① 要求AI提供原文引用
② 接入RAG知识库
③ 精确数字必须人工核查
④ Prompt加「不确定就说不知道」

⚠️ 铁律

AI是「初稿生成器」，不是「权威信息源」。凡涉及工艺参数、品质标准、合规条款，无论AI多么肯定，都要回到原始文件核查。

DAY 30

AGI

// ARTIFICIAL GENERAL INTELLIGENCE · 通用人工智能

AGI指能在任意领域达到人类水平、无需专项训练的通用人工智能。当前所有AI均属专用AI（ANI），AGI尚未实现。

三阶段对比：

ANI（现在）：专用，一件事很强。AI质检、ChatGPT、AlphaGo都是ANI。

AGI（未来，时间不确定）：通用，任意新领域快速达到人类水平，具备跨域迁移能力。

ASI（更远未来）：超人，所有维度全面超越人类。

业界无共识：Sam Altman认为数年内到来；Yann LeCun认为当前路线根本无法通向AGI。

🗡️ 今天所有AI = 专用工具（手术刀/剪刀）；AGI = 完美的瑞士军刀——不只有一把刀，而且每把刀都和专业工具一样好，还能根据需要自己生长出新的刀。

❌ **常见误区**

「AGI没来，AI就不用紧张」— 今天的ANI已在重塑竞争格局。先用好ANI的企业，正在建立成本优势。竞争压力不来自AGI，来自比你先用好ANI的同行。

30个术语 · 快速索引

DAY 01
Token
计量单位/计费基础
中文约1.5字=1Token，按量计费，先估后谈。

DAY 02
Prompt
指令/提示词
四要素：角色+任务+背景+格式，越清晰越好。

DAY 03
大模型
LLM/基础AI
通用基础，需结合工厂数据才能真正落地。

DAY 04
上下文窗口
工作记忆
AI的台面大小，超出则忘，分批处理是解法。

DAY 05
多模态
多感官AI
同时看图文、听语音，直接上传缺陷照片分析。

DAY 06
训练与微调
Fine-tuning
让AI学习专业风格，但不适合做知识库。

DAY 07
推理
Inference
AI思考并回答的过程，产生持续成本。

DAY 08
MCP协议
连接协议
AI连接MES/ERP/飞书的标准接口。

DAY 09
AI Agent
自主智能体
自主完成多步骤任务，从工具变同事。

DAY 10
工具调用
Tool Calling
AI实时调用外部程序获取数据再回答。

DAY 11
LLM
大语言模型
理解意图、灵活应对，但有幻觉风险。

DAY 12
Embedding
语义向量化
文字→数字坐标，实现语义相似度搜索。

DAY 13
RAG
检索增强生成
AI查阅文档再回答，减少幻觉、低成本。

DAY 14
向量数据库
语义存储引擎
RAG系统的知识仓库，支持语义检索。

DAY 15
AIGC
AI生成内容
自动生成报告/图片/翻译，但需人工审核。

DAY 16
生成式AI
Generative AI
能创作新内容，从显示数据到理解数据。

DAY 17
判别式AI
Discriminative AI
专做分类判断，质检首选，速度快成本低。

DAY 18
计算机视觉
Computer Vision
AI看懂图像，质检/缺陷识别/操作规范检测。

DAY 19
NLP
自然语言处理
翻译/摘要/情感分析，多语言工厂必备。

DAY 20
多智能体
Multi-Agent
AI团队分工协作，月报从2天→30分钟。

DAY 21
微调 vs RAG
两条路线
知识库选RAG，风格固化选微调，可结合。

DAY 22

AI原生应用

AI-Native

从设计之初就以AI为核心，非附加功能。

DAY 23

端侧AI

On-device AI

芯片本地运行，零延迟，无网可用，保护隐私。

DAY 24

云侧AI

Cloud AI

远端算力强大，适合复杂推理低频任务。

DAY 25

AI+智能制造

Smart Manufacturing

四层架构从感知到执行，数据治理是前提。

DAY 26

预测性维护

Predictive Maintenance

提前14天预警，非计划停机减少70%+。

DAY 27

AI质检

AI Visual Inspection

误报率8%→0.8%，节省10人时/天。

DAY 28

参数规模

Model Parameters

闭源模型参数未披露，按任务匹配选型。

DAY 29

AI幻觉

AI Hallucination

精确参数必须人工核查，AI是初稿工具。

DAY 30

AGI

通用人工智能

尚未实现。先用好ANI，是当下最务实的选择。

30天 · 完整收官

THANK YOU FOR LEARNING WITH US

AI不是魔法
也不是威胁

它是一套新工具，等待被有准备的人用好

希望这本手册，能让你在遇到AI供应商报价时不被忽悠，
在使用AI工具时少踩坑，在工厂AI改善项目中更有底气。

你已经是那个有准备的人了。